

Statistical Inference and Modeling

2102575

Suwichaya Suwanwimolkul¹

¹Electrical Engineering
Chulalongkorn University

Semester II, 2025

- Lecture 1: Introduction
- Lecture 2: Model selection
- Lecture 3: Resampling
- Lecture 4: Linear regression
- Lecture 5: Robust regression
- Lecture 6: Classification
- Lecture 7: Logistic regression
- Lecture 8: Neural networks
- Lecture 9: K-nearest neighbor
- Lecture 10: Bayesian decision, LDA, QDA, and naive Bayes
- Lecture 11: Support vector machine
- Lecture 12: Tree-based methods
- Lecture 13: Bagging, random forest, boosting
- Lecture 14: Unsupervised learning and clustering algorithms
- Lecture 15: Unsupervised learning and PCA
- Lecture 16: Gaussian mixture model clustering
- Lecture 17: DBSCAN clustering

9 11. Naive Bayes, LDA, QDA

2102575

หน้าตาคล้าย Regression.
ก่อน decision f

Suwichaya Suwanwimolkul¹

¹Electrical Engineering
Chulalongkorn University

Semester II, 2025

- 1 Table of Contents
- 2 Bayesian decision theory
- 3 Naive Bayes
- 4 Decision boundary
- 5 Discriminant function
- 6 Types of naive Bayes
- 7 Extend to multiple observations for training
- 8 Training
 - Training of LDA
- 9 Quadratic discriminant analysis (QDA)

Generative Classifiers

- 1 Table of Contents
- 2 **Bayesian decision theory**
- 3 Naive Bayes
- 4 Decision boundary
- 5 Discriminant function
- 6 Types of naive Bayes
- 7 Extend to multiple observations for training
- 8 Training
- 9 Quadratic discriminant analysis (QDA)

Terminology in Bayesian theory

- **Prior probability** $p(x)$ is the knowledge we have *before* looking at an observed x .
- **Class likelihood** or **class-conditional density** $p(x|y)$ gives distribution information of features in each class (once we know the response variable belong to the class y)
- **Evidence** $p(x)$ is the marginal probability that a value x is observed (regardless of the class of Y) —can be computed using total probability.
- **Posterior probability** $p(y|x)$ is the likelihood of response after x is seen.

Bayes' rule: Posterior = $\frac{\text{class likelihood} \times \text{prior}}{\text{evidence}}$

$$p(y = c|x) = \frac{p(x|y = c)p(y = c)}{p(x)}$$

* prior *

เป้าหมายเราในการหา Loss function
ของ discriminative task ∇ .

เรามักจะ neglect

From a discriminative task to generative classifiers (naive Bayes)

We call something is "discriminative" if $\hat{\theta} = \underset{\theta}{\operatorname{argmax}} p(x|\theta)$ where x is observation
 otherwise, that something is generative.

บทนี้ยังคงเป็น Parametric Model เพราะ Model
 เราตั้ง Assume Based on บาง distribution ที่เราตั้ง

A common goal in discriminative task is

$$\hat{c} = \underset{c \in \{1, 2, \dots, C\}}{\operatorname{argmax}} p(x|y=c) = \text{likelihood}$$

which is to find the class c that has the highest likelihood...

Let's turn this problem into a **generative task**:

$$\hat{c} = \underset{c \in \{1, 2, \dots, C\}}{\operatorname{argmax}} p(y=c|x) = \frac{p(x|y=c)p(y=c)}{p(x)}$$

เรา consider มัน

generative tasks.

↓ ว่าเป็น distribution ใด.

Learning parameters: $\mu_{y=c}, \sigma_{y=c}^2, \forall c \in \{1, 2, \dots, C\}$

$$p(x|y=c; \mu_{y=c}, \sigma_{y=c}^2)$$

($p(x)$) เราละเลย.

generative & learning.

↪ สักการะเรา: neglect.

To solve for c , one needs to calculate the following terms:

- **Prior**: $p(y=c)$ can be computed using the fraction of each class from the training data.
- **Likelihood** $p(x|y=c)$ can be computed using the distribution of input features x , which can be partially parameterized by the condition of each class $y=c$ for $c \in \{1, 2, \dots, C\}$.
- **This setting we are interested in identifying the class of a given input x .**

$a^* = [1000, 2, 10, 1]$; $a_old = -inf$
 for a in a^* :
 if $a > a_old$: $a_old = a$

เราจับ x มาในเทอม likelihood เพื่อมา full-filled information.

Decision boundary

Decision rule: suppose that $c \in \{0, 1\}$.

- Classifying to $c = 0$

$$\begin{aligned} p(y = 0|x) > p(y = 1|x) &\iff \log p(x|y = 0) + \log p(y = 0) > \log p(x|y = 1) + \log p(y = 1) \\ &\iff \log g_{c=0}(x) > \log g_{c=1}(x) \end{aligned}$$

- Classifying to $c = 1$

$$\begin{aligned} p(y = 1|x) > p(y = 0|x) &\iff \log p(x|y = 1) + \log p(y = 1) > \log p(x|y = 0) + \log p(y = 0) \\ &\iff \log g_{c=1}(x) > \log g_{c=0}(x) \end{aligned}$$

discriminant function

ในทางคำนวณ เราจะคำนวณ $p(y=c) \approx \frac{1}{n} \sum_j I(y_j=c)$; $\forall c \in C$ ซึ่งเรามองว่ามันคือ bias term
แต่ในชีวิตจริง มันมีอยู่ละ-โลการที่เราไปเก็บข้อมูลมาแล้วมี Class บางกลุ่มที่มีเยอะเป็นพิเศษ.
ปล. ในตอนที่เรียน Logistic เราก็มีเหมือนกัน แต่จะอยู่ที่ β .

Decision boundary

เป็น Classification เหมือนกัน,

ตารางเปรียบเทียบ: Logistic Regression vs Generative Models

หัวข้อเปรียบเทียบ	Logistic Regression	Linear Discriminant Analysis (LDA)	Quadratic Discriminant Analysis (QDA)	Naive Bayes
ประเภทโมเดล	Discriminative	Generative	Generative	Generative
เป้าหมายหลัก	หา $P(Y X)$ โดยตรง (หาเส้นแบ่ง)	หา $P(X Y)$ และ $P(Y)$ (จำลองการกระจายตัวของข้อมูล)	หา $P(X Y)$ และ $P(Y)$ (จำลองการกระจายตัวของข้อมูล)	หา $P(X Y)$ และ $P(Y)$ (จำลองการกระจายตัวของข้อมูล)
วิธีการเรียนรู้ (How to Learn)	Iterative Optimization	Closed-form Analytic	Closed-form Analytic	Closed-form Analytic
	ใช้ Maximum Likelihood Estimation (MLE) แต่สามารถด้วย Gradient Descent หรือ Newton's Method เพื่อหาค่า β ที่ดีที่สุด (ไม่มีสูตรสำเร็จ)	คำนวณค่าสถิติจากข้อมูลโดยตรง: 1. Mean (μ_c) ของแต่ละคลาส 2. Shared Covariance (Σ) ร่วมกันทุกคลาส 3. Prior (π_c) จากสัดส่วนข้อมูล	คำนวณค่าสถิติจากข้อมูลโดยตรง: 1. Mean (μ_c) ของแต่ละคลาส 2. Separate Covariance (Σ_c) แยกกันแต่ละคลาส 3. Prior (π_c) จากสัดส่วนข้อมูล	คำนวณความน่าจะเป็นหรือหาพารามิเตอร์แยกแยะฟีเจอร์ (Feature) ตามสมมติฐานว่า ตัวแปรอิสระต่อกัน (Independent)
รูปร่าง Decision Boundary	Linear (เส้นตรง/ระนาบ)	Linear (เส้นตรง/ระนาบ)	Quadratic (เส้นโค้ง/วงรี)	อาจเป็น Linear หรือ Non-linear ขึ้นอยู่กับ Distribution ที่เลือกใช้
ความซับซ้อน (Parameters)	ต่ำ (มีแค่ค่า β)	ปานกลาง (ต้องหา Σ หนึ่งก้อน)	สูง (ต้องหา Σ_c หลายก้อนตามจำนวนคลาส)	ต่ำมาก (เพราะคิดแยกฟีเจอร์ ไม่ต้องหา Covariance ระหว่างกัน)

1. Generative classifier

- ↳ สร้างกราฟ PDF ของแต่ละ Class
- ↳ สันนิษฐานหาของข้อมูลทุก Class แล้วคำนวณหาแบบที่เหมะสม.

2. Discriminative classifier

- ↳ สร้างสมการเส้นแบ่ง (Decision Boundary) หรือ Rule ที่บอกว่า อยู่ Class ไหน

Discriminant function

What define $g_c(x)$?

$$\begin{aligned} g_c(x) &\propto p(y = c|x) \\ &\propto p(x|y = c)p(y = c) \quad \star \end{aligned}$$

discrete distribution
was Prob class ing.

① **Prior:** $p(y = c)$ can be computed using the fraction of each class from the training data. It can be seen as the weight for each class.

② **Likelihood** $p(x|y = c)$ can be computed in the following manners:

→ if we did not assume any distribution on $p(x|y = c)$, then the generative task is just a **Naive Bayes**.

$$\rightarrow \text{if } p(x|y = c) := \begin{cases} q_c & \text{if } x = 1 \\ 1 - q_c & \text{otherwise} \end{cases} \quad g_c(x) = \begin{cases} g_c(x) \cdot p(y=c) & ; x=1 \\ (1-g_c(x)) \cdot p(y=c) & ; x=0 \end{cases}$$

where x can only be either 0 or 1, then we call it **Bernoulli Naive Bayes**. Note that q_c is the corresponding event when $x = 1$ and can be controlled by $y = c$.

→ if $p(x|y = c) := \frac{1}{\sqrt{2\pi\sigma_c^2}} \exp - \frac{(x-\mu_c)^2}{2\sigma_c^2}$, then we call it **Gaussian Naive Bayes**. Notice that μ_c, σ_c^2 are the parameters associated with the distribution of input features x and can be controlled by $y = c$.

Example: Bernoulli Naive Bayes ★


Suppose that $y \sim \mathcal{U}(0, C)$ and $p(x|y=c)$ is a Bernoulli distribution parameterized according to the following:

$$f_y(y) = \frac{1}{C}$$

$$p(x|y=c) := \begin{cases} q_c & \text{if } x = 1 \\ 1 - q_c & \text{otherwise} \end{cases}$$

where the value of q_c depends on the value of $c \in \{0, 1, \dots, C\}$.

How to formulate the discriminant function $g_c(\cdot)$?



$$g_c(x) \propto p(x|y=c)p(y=c)$$

$$\propto (q_c)^x (1 - q_c)^{1-x} \frac{1}{C} \rightarrow \text{discriminant } f^y$$

To simplify the above formulation for computation, we can compute $g_c(x)$ in logarithmic scale:

$$\begin{aligned} g_c(x) &= \log (q_c)^x (1 - q_c)^{1-x} \frac{1}{C} \\ &= x \log (q_c) + (1 - x) \log (1 - q_c) - \log C \\ &= x (\log (q_c) - \log (1 - q_c)) + \log (1 - q_c) - \log C \end{aligned}$$

Note $g_c(c)$ is a linear function in x .

Example: Gaussian Naive Bayes

★ ตัวนี้เป็นฐานการไปหา LDA, QDA.

Suppose that $y \sim \mathcal{U}(0, C)$ and $p(x|y = c)$ is parameterized according to the following:

$$f_Y(y) = \frac{1}{C}$$

$$p(x|y = c) := \frac{1}{\sqrt{2\pi\sigma_c^2}} \exp - \frac{(x - \mu_c)^2}{2\sigma_c^2}$$

where μ_c and σ_c depends on the value of $c \in \{0, 1, \dots, C\}$. How to formulate $g_c(\cdot)$?

$$\begin{aligned} g_c(x) &\propto p(x|y = c)p(y = c) \\ &\propto \frac{1}{\sqrt{2\pi\sigma_c^2}} \exp - \frac{(x - \mu_c)^2}{2\sigma_c^2} \frac{1}{C} \end{aligned}$$

To simplify the above formulation for computation, we can compute $g_c(x)$ in logarithmic scale:

ถ้าเราบอกว่า $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_C^2$
เวลาให้ $X_{1|Y=C_1}, X_{1|Y=C_2}$
ใน $g_c(x)$ มันจะได้ $-\frac{1}{2\sigma_c^2}x^2$ เดียวกัน
เลขเหมือนกันไม่จำเป็นต้องการเปรียบเทียบ.

$$g_c(x) = \log \left(\frac{1}{\sqrt{2\pi\sigma_c^2}} \right) + \log \left(\exp - \frac{(x - \mu_c)^2}{2\sigma_c^2} \right) + \log \left(\frac{1}{C} \right)$$

$$= -\log \sqrt{2\pi\sigma_c^2} - \frac{(x - \mu_c)^2}{2\sigma_c^2} - \log C$$

LDA: $\beta_1 x + \beta_0$

$$= -\frac{1}{2\sigma_c^2} x^2 + \frac{\mu_c}{\sigma_c^2} x - \frac{\mu_c^2}{2\sigma_c^2} - \log \sqrt{2\pi\sigma_c^2} - \log C$$

QDA: $\beta_2 x^2 + \beta_1 x + \beta_0$

ไปอยู่ใน proof
ด้านล่าง.

If $\sigma_c^2 = \sigma^2$ for all $c \in \{1, 2, \dots, C\}$, then the term $\frac{1}{2\sigma^2} x^2$ can be ignored, and thus, $g_c(x)$ will be a linear function in x . Otherwise, $g_c(x)$ is quadratic function in x .

Types of naive Bayes

A common goal in discriminative classification is

$$\hat{c} = \underset{c=1,2,\dots,C}{\operatorname{argmax}} p(y=c|x) = \frac{p(x|y=c)p(y=c)}{p(x)} = g_c(x|\mu_c, \Sigma_c)$$

Inference. The discriminant function $g_l(x|\mu_c, \Sigma_c)$.

- Naive Bayes: $\log g_c(x|\mu_c, \Sigma_c)$ is directly derived from

$$g_c(x|\mu_c, \Sigma_c) \propto \prod_{j=1}^m p(x_j|y_j)p(y_j)$$

likelihood fⁿ

discrete pmf of Y

- LDA : $\log g_c(x|\mu_c, \Sigma_c)$ is a linear discriminant function, i.e.,

$$\text{Special Case ; } \sigma_c^2 = \sigma^2 \rightarrow \log g_c(x|\mu_c, \Sigma_c) \approx \beta_1 x + \beta_0$$

- QDA : $\log g_c(x|\mu_c, \Sigma_c)$ is a quadratic discriminant function.

$$\log g_c(x|\mu_c, \Sigma_c) \approx \beta_2 x^2 + \beta_1 x + \beta_0$$

Side notes:


- The parameters associated with $x|y$, e.g., q, μ, Σ , are estimated from sample mean and variance of the training data. $\rightarrow$ *Maximum Likelihood Optimization Problem with Regression*
- The estimated mean and variance depends on how x is divided into classes.

Bayes decision boundary: scalar case

An example of posterior densities for two cases of prior probabilities;

$$P(Y = 1) = P(Y = 2) = 0.5$$


$$P(Y = 1) = 0.3, P(Y = 2) = 0.7$$



- For a given test observation x , assign to the class for which the density is highest either **class 1** or **class 2**.
- When the prior of **class 2** is higher, the decision boundary is shifted to the left (more favor to **class 2**).
↳ $P(Y=2) > P(Y=1)$

Example: conditional 2D Gaussians

$$X|y = 1 \sim \mathcal{N}\left(\begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix}\right) \text{ and } X|y = 2 \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right)$$



- Bayes decision boundary of Gaussian case leads to a quadratic function.
- What happens to the decision boundary as $p(y = 1)$ increases?

Extend to multiple observations for training

- Suppose that our training dataset contains m observation pairs of input features and labels (x_j, y_j) for $j = 1, \dots, m$.
- Then, the posterior distribution is

$$\prod_{j=1}^m p(y_j | x_j) \propto \prod_{j=1}^m p(x_j | y_j) p(y_j)$$

มอง $x_j \in \mathbb{R}^1$ (ตัวเลขปกติ)

Therefore, the discriminant function for a training dataset can be formulated as follows:

$$g_c(x | \mu_c, \Sigma_c) \propto \prod_{j=1}^m p(x_j | y_j) p(y_j)$$

- **Multi-dimensional case.**

However, in most cases, x_j is an n -dimensional input features, i.e., $x_j := [x_j^i]_{i \in [n]}$. Thus, we can write $p(x_j | y_j)$ as

$$p(x_j | y_j) = p([x_j^i]_{i \in [n]} | y_j)$$

$[x_j^i] = [x_j^1 \ x_j^2 \ \dots \ x_j^n]$
= data sample j

Therefore, the discriminant function can be formulated as follows:

$$g_c(x | \mu_c, \Sigma_c) \propto \prod_{j=1}^m p([x_j^i]_{i \in [n]} | y_j)$$

- Training of LDA

Training of LDA: problem settings

$$\sigma_{c=1}^2 = \sigma_{c=2}^2 \dots = \sigma_c^2 = \Sigma \rightarrow \text{แบบ Over simplify} \rightarrow \text{High bias. (Underfit)}$$

Assumption.

LDA applies a **Gaussian assumption with equal covariance** on $p(x|y=c)$.

- $p(x|y=c)$ is a Gaussian with mean μ_c and equal covariance Σ_c for $c = 1, \dots, C$
- Let $p_c(x)$ denotes the posterior probability $\triangleq P(y=c|x) \propto \frac{p(x|y=c)p(y=c)}{p(x)}$:

คำนวณทุกๆ คลาส $c \rightarrow p_c(x) = \frac{\exp\left(-\frac{1}{2}(x - \mu_c)^T \Sigma_c^{-1}(x - \mu_c)\right) \pi_c}{\sum_{k=1}^C \exp\left(-\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k)\right) \pi_k}$

$\pi_c = P(y=c)$

- Note:** the denominators are the same, regardless of the density and classes.

Inference.

Take the $\log p_c(x)$ and neglect the term $x^T \Sigma^{-1} x$, we predict the class c for which a discriminant function (defined below) is the highest among $c = 1, 2, \dots, C$

Discriminant function: $g_c(x) = x^T \Sigma^{-1} \mu_c - \frac{1}{2} \mu_c^T \Sigma^{-1} \mu_c + \log \pi_c$

$= x^T \beta_1 + \beta_0 \rightarrow \text{รูป form การถดถอยเชิงเส้น: คล้ายๆ Linear Regression}$

Decision boundary of LDA: Training

Training.

- The decision boundary between a and b happens when the two classes have equal discriminant values.

$$g_a(x) = g_b(x) \iff g_a(x) - g_b(x) = 0$$

$$\iff \left(x^T \Sigma^{-1} \mu_a - \frac{1}{2} \mu_a^T \Sigma^{-1} \mu_a + \log \pi_a \right) - \left(x^T \Sigma^{-1} \mu_b - \frac{1}{2} \mu_b^T \Sigma^{-1} \mu_b + \log \pi_b \right) = 0$$

$$\iff x^T \hat{\Sigma}^{-1} (\hat{\mu}_a - \hat{\mu}_b) - \frac{1}{2} (\hat{\mu}_a^T \hat{\Sigma}^{-1} \hat{\mu}_a - \hat{\mu}_b^T \hat{\Sigma}^{-1} \hat{\mu}_b) + \log \frac{\hat{\pi}_a}{\hat{\pi}_b} = 0$$

- The decision boundary is **linear** in x .
- When **prior densities are equal**, the **boundary is the midpoint of any two sample means of x** associated with each pair of classes: $x = \frac{1}{2} (\hat{\mu}_a + \hat{\mu}_b)$. This can be derived from

$$x^T \hat{\Sigma}^{-1} (\hat{\mu}_a - \hat{\mu}_b) - \frac{1}{2} (\hat{\mu}_a^T \hat{\Sigma}^{-1} \hat{\mu}_a - \hat{\mu}_b^T \hat{\Sigma}^{-1} \hat{\mu}_b) = 0$$

$$x^T \hat{\Sigma}^{-1} (\hat{\mu}_a - \hat{\mu}_b) = \frac{1}{2} (\hat{\mu}_a + \hat{\mu}_b)^T \hat{\Sigma}^{-1} (\hat{\mu}_a - \hat{\mu}_b)$$

- This means that μ_c for x associated with each class can be calculated from

$$\hat{\mu}_c = \text{sample mean of } X \text{ in class } c$$

- Then, the variance $\hat{\Sigma} = \frac{1}{m-C} \sum_{c=1}^C \sum_{j \in [m] | y_j = c} (x_j - \hat{\mu}_c)(x_j - \hat{\mu}_c)^T$.

Training phase: compute $p(y = c)$, $\hat{\mu}_c$, and $\hat{\Sigma}$

① **Partition data:**

Partition y_j for $j \in [m]$ according to its associated labels y_j : $\mathcal{Y}_c = \{y_j, j \in [m] | y_j = c\}$.
For example: $\mathcal{Y}_{c=0} = \{y_j, j \in [m] | y_j = 0\}$, $\mathcal{Y}_{c=1} = \{y_j, j \in [m] | y_j = 1\}$, ..., $\mathcal{Y}_{c=C} = \{y_j, j \in [m] | y_j = C\}$.

Partition x_j for $j \in [m]$ according to its associated labels y_j : $\mathcal{X}_c = \{x_j, j \in [m] | y_j = c\}$.
For example: $\mathcal{X}_{c=0} = \{x_j, j \in [m] | y_j = 0\}$, $\mathcal{X}_{c=1} = \{x_j, j \in [m] | y_j = 1\}$, ..., $\mathcal{X}_{c=C} = \{x_j, j \in [m] | y_j = C\}$.

② **Compute $p(y = c)$ for all $c \in \{1, 2, \dots, C\}$.**

$$p(y = 0) = \frac{|\mathcal{Y}_{c=0}|}{m}, p(y = 1) = \frac{|\mathcal{Y}_{c=1}|}{m}, \dots, p(y = C) = \frac{|\mathcal{Y}_{c=C}|}{m}$$

③ **Compute $\hat{\mu}_c$ for all $c \in \{1, 2, \dots, C\}$.**

$$\hat{\mu}_{c=0} = \frac{\sum_{x \in \mathcal{X}_{c=0}} x}{|\mathcal{X}_{c=0}|}, \hat{\mu}_{c=1} = \frac{\sum_{x \in \mathcal{X}_{c=1}} x}{|\mathcal{X}_{c=1}|}, \dots, \hat{\mu}_{c=C} = \frac{\sum_{x \in \mathcal{X}_{c=C}} x}{|\mathcal{X}_{c=C}|}$$

④ **Compute $\hat{\Sigma}$...**

$$\hat{\Sigma} = \frac{1}{m - C} \sum_{c=1}^C \sum_{x \in \mathcal{X}_c} (x - \hat{\mu}_c)(x - \hat{\mu}_c)^T$$

Inference phase

Given the input x , **discriminant function** is computed for all $c \in \{0, 1, 2, \dots, C\}$:

$$g_c(x) = x^T \hat{\Sigma}^{-1} \hat{\mu}_c - \frac{1}{2} \hat{\mu}_c^T \hat{\Sigma}^{-1} \hat{\mu}_c + \log p(y = c)$$

Training of LDA: problem settings

$$g_c(x) = x^T \Sigma^{-1} \mu_c - \frac{1}{2} \mu_c^T \Sigma^{-1} \mu_c + \log \pi_c \quad (*)$$

1. การเรียนรู้ (Learning Phase) = "การหาค่าสถิติ 3 ตัว"

ในขั้นตอนการเรียนรู้ LDA จะทำหน้าที่เหมือน "นักสถิติ" ที่กวาดตาดูข้อมูลทั้งหมด แล้วจัดบันทึกค่าสำคัญ 3 อย่างเก็บไว้เป็น "ความรู้" (Model Parameters) ครั้น:

1. หากความน่าจะเป็นตั้งต้น (Prior π_k):

- **ทำอย่างไร:** นับจำนวนสมาชิกในแต่ละคลาส หาดด้วยจำนวนข้อมูลทั้งหมด
- **ตัวอย่าง:** มีข้อมูล 100 ตัว เป็นคลาส A 30 ตัว, คลาส B 70 ตัว
- **ค่าที่จำ:** $\pi_A = 0.3, \pi_B = 0.7$

2. หาค่าเฉลี่ยของแต่ละคลาส (Mean μ_k):

- **ทำอย่างไร:** เอาข้อมูล x ทั้งหมดที่เป็นคลาส A มาหาจุดกึ่งกลาง (Average) และทำแบบเดียวกันกับคลาส B
- **ค่าที่จำ:** จุดศูนย์กลางของกลุ่ม A (μ_A) และจุดศูนย์กลางของกลุ่ม B (μ_B)

3. หากความแปรปรวนร่วม (Pooled Covariance Σ):

- **ทำอย่างไร:** คำนวณว่าข้อมูลมีการกระจายตัวกว้างแค่ไหนและมีรูปร่างรีหรือกลม
- **จุดสำคัญของ LDA:** LDA จะบังคับว่า "ทุกคลาสต้องใช้ทรงเดียวกัน" ดังนั้นมันจะคำนวณ Covariance ของแต่ละคลาส แล้วเอามา "เฉลี่ยรวมกัน" (Weighted Average) ให้เป็นก้อนเดียวกันหมด
- **ค่าที่จำ:** เมทริกซ์ Σ ก้อนเดียว

สรุปการ Learn: พอคำนวณ 3 ตัวนี้เสร็จ (π, μ, Σ) ถือว่า "เทรนเสร็จแล้ว" ครับ (เร็วกว่า Logistic Regression มากเพราะแค่บวกคูณหาขอบเขต)

2. การบอกผลลัพธ์ (Output Phase) = "การเทียบคะแนน"

เมื่อมีข้อมูลใหม่ x เข้ามา LDA จะบอก Output ผ่านการคำนวณ "Discriminant Score" ($g_k(x)$) ครับ

วิธีการคำนวณ Output:

LDA จะเอา x ไปใส่สมการเส้นตรง (Linear Equation) ของแต่ละคลาส เพื่อดูว่าคะแนนของคลาสไหนเยอะกว่ากัน

สมการคะแนนของคลาส k ($\delta_k(x)$):

$$\delta_k(x) = \underbrace{x^T \Sigma^{-1} \mu_k}_{\text{เหมือน Weight } \beta} - \underbrace{\frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k}_{\text{เหมือน Bias/Intercept}}$$

$= g_k(x)$

รูปแบบของ Output ที่เราจะได้:

1. Discriminant Score (คะแนนดิบ):

- จะได้ค่าตัวเลขออกมา 2 ค่า (ถ้ามี 2 คลาส) เช่น
 - Score(Class A) = 5.2
 - Score(Class B) = 3.8

$$\hat{C} = \max_{c \in C} \text{Score}$$



2. Predicted Class (คลาสที่ทำนาย):

- เลือกคลาสที่คะแนนสูงสุด $\rightarrow$ **ตอบ Class A**

3. Posterior Probability (ความน่าจะเป็น):


- เราสามารถแปลง Score สลับเป็น % ได้โดยใช้ Softmax function
- เช่น $P(y = A|x) = 0.8, P(y = B|x) = 0.2$

LDA decision boundaries for scalar x



- **Setting:** Let the true densities be Gaussian distributions: $P(x|y = 0)$ with $\mu_1 = -1.25$ and $P(x|y = 1)$ with $\mu_2 = +1.25$ and unit variances for both. Draw 20 observations from each class.
- One can use Bayes decision (left) is then $x = (\mu_1 + \mu_2)/2 = 0$, which is unknown in real-life.
- The area for which two densities overlapped is the classification error
- LDA decision boundary (solid line) is a little off from Bayes since it uses the sample mean computed from the training data.

LDA decision boundaries for a vector of x



- **Setting:** 3-class, true distribution is Gaussian with equal Σ , 20 samples for each class
- Bayes decision boundary and 95% confidence ellipsoid (use true μ_c, Σ).
- Solid lines are LDA decision boundaries ($\hat{\mu}_c, \hat{\Sigma}$). Dashed lines are Bayes.

Quadratic discriminant analysis (QDA)

Assumption.

QDA assumes observations in each class are **Gaussian** but each has its own covariance matrices — the posterior probability $p_c(x) \triangleq P(y = c|x)$ is

$$\rightarrow X|y=c \sim \mathcal{N}(\mu_c, \Sigma_c)$$

└ จุดแตกต่างหลักกับ LDA

$$p_c(x) = \left[\frac{\exp \left[-\frac{1}{2}(x - \mu_c)^T \Sigma_c^{-1} (x - \mu_c) \right] \cdot \pi_c}{(2\pi)^{n/2} (\det \Sigma_c)^{1/2}} \right] / p(x)$$

Inference.

QDA follows Bayes classifier to perform the prediction, choosing the class l where

$$\text{Discriminant func.: } g_c(x) = -\frac{1}{2}(x - \mu_c)^T \Sigma_c^{-1} (x - \mu_c) - \frac{1}{2} \log \det \Sigma_c + \log \pi_c$$

is **highest** among $c = 1, 2, \dots, C$; however, it uses **estimates of μ_c, Σ_c** .

- the **decision boundary** between class c and k is given by the set of x that $g_c(x) = g_k(x)$ — becoming **quadratic** function in x .
- QDA has **more number of parameters to estimate** — leading the chance of getting less bias but also higher variance than LDA.

Comparison between LDA and QDA

Assume n feature dimension and C class

$O(n^3)$

method	number of parameters	model property
LDA	$c(n+1)$	low flexibility, low variance
QDA	$\frac{n(n+1)C}{2}$	high flexibility, high variance

feature dimension = 2 $\rightarrow K \in \mathbb{R}^2$



Class 1 $\{ (x_1, x_2)^{je M_1} \} \rightarrow (\mu_{x_1}^{C=1}, \mu_{x_2}^{C=1})$
 Class 2 $\{ (x_1, x_2)^{je M_2} \} \rightarrow (\mu_{x_1}^{C=2}, \mu_{x_2}^{C=2})$
 $\vdots$
 Class 10 $\{ (x_1, x_2)^{je M_{10}} \} \rightarrow (\mu_{x_1}^{C=10}, \mu_{x_2}^{C=10})$

$\times 10$

$\mu_{C=1}$
 $\mu_{C=2}$
 $\vdots$
 $\mu_{C=10}$

$n^2 - n$

Comparison: Gaussian with *left*: common and *right*: different covariances.



- *Left*: Bayes decision boundary is linear and accurately approx. LDA
- *Right*: now Bayes decision boundary is quadratic, and QDA is more accurate.

$= c \left(1 + n + \frac{(n^2 - n)}{2} + n \right)$

Prior $\mu_C \in \mathbb{R}^n$
 Mean $\mu_C \in \mathbb{R}^n$
 Covariance $\Sigma_C \in \mathbb{R}^{n \times n}$
 Symmetry matrix $n \times n$

$\frac{n^2 - n}{2} + n$ — Cov.

Comparison between LDA and QDA

จำนวน $\hat{\theta}_c = \{\hat{\mu}_c, \hat{\Sigma}_c, \hat{\pi}_c\}$

①. หา $\hat{\mu}_c = [\hat{\mu}_{1c} \ \hat{\mu}_{2c} \ \dots \ \hat{\mu}_{nc}]^T$

②. หา $\hat{\Sigma}_c = \begin{bmatrix} \sigma_{11}^{1,c} & \sigma_{12}^{1,c} & \sigma_{13}^{1,c} & \dots & \sigma_{1n}^{1,c} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1}^{2,c} & \sigma_{n2}^{2,c} & \sigma_{n3}^{2,c} & \dots & \sigma_{nn}^{2,c} \end{bmatrix}_{n \times n}$

③. หา $\hat{\pi}_c$ (bias term)

เมื่อ C เพิ่มขึ้น: ทำให้ # parameters ใน QDA $\gg$ LDA ส่งผลให้มัน Lead ไปสู่การ "Overfit" ได้ง่าย.

LDA

QDA.

$C \cdot n$ $\downarrow$ # parameters Class $\overrightarrow{C \cdot n}$

$1 + \frac{n(n-1)}{2}$
 $C \left(n + \frac{n(n-1)}{2} \right)$
 $\uparrow$
 $\sigma_{ij} \mid i \neq j$

บางทีก็ทำ: $C-1$ เพราะหาพจน์ $c-1$ class
 อีก class 1: $1 - \sum_{j=1}^{c-1} \hat{\pi}_j$


Augmented features in LDA vs QDA

เป็นหลายคือลด Time Consume, Significantly Separate

เราอาจแปลง X เป็นอย่างอื่นได้ เช่น Laplace, Fourier, ..., Polynomial

Feature spaces: original and its mapping by a quadratic function.

Original: $\{X_1, X_2, \dots, X_n\}$, Augmented: $\{X_1, X_2, \dots, X_n, X_1^2, X_2^2, \dots, X_n^2\}$



- *Middle*: linear functions of LDA performed on the augmented space results in quadratic functions in the original space.
- While preferring QDA, the differences between QDA and LDA (middle) are small.

Comparing LDA, QDA, and Naïve Bayes

These classifiers have a common goal, *i.e.*, to assign an observation to the class that maximizes $P(y = c|x)$.

Let's set C as a *baseline class*; equivalently, we aim at assigning an observation that maximize the followings, for $c = 1, \dots, K$,

$$\log \left(\frac{P(y = c|x)}{P(y = C|x)} \right).$$

Comparing LDA, QDA, and Naïve Bayes: LDA

LDA: predictors within each class are drawn from a multivariate normal density with class-specific mean and **shared** co-variance matrix.

$$\begin{aligned}\log \left(\frac{P(y = c|x)}{P(y = C|x)} \right) &= \log \left(\frac{\pi_c f_c(x)}{\pi_C f_C(x)} \right) \\&= \log \left(\frac{\pi_c \exp \left(-\frac{1}{2} (x - \mu_c)^T \Sigma^{-1} (x - \mu_c) \right)}{\pi_C \exp \left(-\frac{1}{2} (x - \mu_C)^T \Sigma^{-1} (x - \mu_C) \right)} \right) \\&= \log \left(\frac{\pi_c}{\pi_C} \right) - \frac{1}{2} (\mu_c + \mu_C)^T \Sigma^{-1} (\mu_c - \mu_C) \\&\quad + x^T \Sigma^{-1} (\mu_c - \mu_C) \\&= a_c + \sum_{i=1}^n b_{ci} x_i\end{aligned}$$

where $a_c = \log \left(\frac{\pi_c}{\pi_C} \right) - \frac{1}{2} (\mu_c + \mu_C)^T \Sigma^{-1} (\mu_c - \mu_C)$ and b_{ci} is the i th component of $\Sigma^{-1} (\mu_c - \mu_C)$. Hence LDA, like ~~logistic~~ linear regression, has the log odds of the posterior probabilities is linear in x .

QDA has the **log odds** of the posterior probabilities is quadratic in x .

$$\log \left(\frac{P(y = c|x)}{P(y = C|x)} \right) = a_c + \sum_{i=1}^n b_{ci}x_i + \sum_{p=1}^n \sum_{i=1}^n c_{cip}x_ix_p$$

where a_c, b_{ci}, c_{cip} are functions of $\pi_c, \pi_C, \mu_c, \mu_C$ and Σ .

Comparing LDA, QDA, and Naïve Bayes: Naïve Bayes

Naïve Bayes: assume conditional independency among features given a label k .

$$\begin{aligned}\log \left(\frac{P(y = c|x)}{P(y = C|x)} \right) &= \log \left(\frac{\pi_c f_c(x)}{\pi_C f_C(x)} \right) \quad \text{Independent.} \\ &= \log \left(\frac{\pi_c \prod_{i=1}^n f_{ci}(x_i)}{\pi_C \prod_{i=1}^n f_{Ci}(x_i)} \right) \\ &= \log \left(\frac{\pi_c}{\pi_C} \right) + \sum_{i=1}^n \log \left(\frac{f_{ci}(x_i)}{f_{Ci}(x_i)} \right) \\ &= a_c + \sum_{i=1}^p g_{ci}(x_i)\end{aligned}$$

where $a_c = \log \left(\frac{\pi_c}{\pi_C} \right)$ and $g_{ci}(x_i) = \log \left(\frac{f_{ci}(x_i)}{f_{Ci}(x_i)} \right)$

Methods	Python (scikit-learn)
Logistic regression	<code>linear-model.LogisticRegression</code>
Naïve Bayes	<code>naive-bayes</code>
kNN	<code>neighbors.KNeighborsClassifier</code>
LDA, QDA	<code>discriminant-analysis</code>

- [1] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer Series in Statistics. New York, NY, USA: Springer New York Inc., 2001.
- [2] Gareth James et al. *An Introduction to Statistical Learning: with Applications in R*. Springer, 2013. URL: <https://faculty.marshall.usc.edu/gareth-james/ISL/>.
- [3] Jitkomut Songsiri. “Statistical Learning”. In: in EE575 Random Processes for EE. Chulalongkorn University, 2022. Chap. 8. Introduction to Classification. URL: <http://jitkomut.eng.chula.ac.th/ee575.html>.

Example: conditional 2D Gaussians ($\eta=2$)

Proof Decision Boundary ของ 2D Gaussians

ให้ $X|y=c \sim \text{Normal}(\underline{\mu}_c, \Sigma_c)$ โดย $\underline{\mu}_c = \begin{bmatrix} \mu_{1c} \\ \vdots \\ \mu_{nc} \end{bmatrix}_{n \times 1}$ และ

covariance matrix of X

$$\Sigma_c = \begin{bmatrix} \sigma_{11}^{2,c} & \sigma_{12}^{2,c} & \dots & \sigma_{1n}^{2,c} \\ \sigma_{12}^{2,c} & \sigma_{22}^{2,c} & & \vdots \\ \vdots & & \ddots & \vdots \\ \sigma_{1n}^{2,c} & \dots & \dots & \sigma_{nn}^{2,c} \end{bmatrix}_{n \times n}$$

ซึ่ง $\mu_{ic} = \frac{\text{ค่า } X \text{ พยอกตาม features } i, \text{ Class } c}{\text{จำนวนค่า } X \text{ features } i, \text{ Class } c}$; $\mu_{i,c}$

$\sigma_i^{2,c}, \sigma_{ij}^{2,c} (i \neq j)$ ก็คำนวณตามปกติ โดยแยกตาม c

$$\text{จาก } g_c(X) = \log[P(X|Y=c)] + \log \pi_c$$

$$= \log \left\{ \frac{1}{(2\pi)^n |\Sigma_c|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (\underline{X} - \underline{\mu}_c)^T \Sigma_c^{-1} (\underline{X} - \underline{\mu}_c) \right] \right\} + \log \pi_c$$

$$= -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log(\det \Sigma_c) - \frac{1}{2} (\underline{X} - \underline{\mu}_c)^T \Sigma_c^{-1} (\underline{X} - \underline{\mu}_c) + \log \pi_c$$

$$= -\frac{1}{2} (\underline{X} - \underline{\mu}_c)^T \Sigma_c^{-1} (\underline{X} - \underline{\mu}_c) - \frac{1}{2} \log(\det \Sigma_c) - \frac{n}{2} \log(2\pi) + \log \pi_c$$

Example: conditional 2D Gaussians

$$g_c(\underline{x}) = -\frac{1}{2}(\underline{x} - \underline{\mu}_c)^T \underline{\Sigma}_c^{-1}(\underline{x} - \underline{\mu}_c) - \frac{1}{2} \log(\det \underline{\Sigma}_c) - \frac{n}{2} \log(2\pi) + \log \pi_c$$

$$= -\frac{1}{2} \left(\underline{x}^T \underline{\Sigma}_c^{-1} \underline{x} + 2 \underline{\mu}_c^T \underline{\Sigma}_c^{-1} \underline{x} + \underline{\mu}_c^T \underline{\Sigma}_c^{-1} \underline{\mu}_c \right) - \frac{1}{2} \log(\det \underline{\Sigma}_c) - \frac{n}{2} \log(2\pi) + \log \pi_c$$

$$g_c(\underline{x}) = -\frac{1}{2} \underline{x}^T \underline{\Sigma}_c^{-1} \underline{x} - \underbrace{\underline{\mu}_c^T \underline{\Sigma}_c^{-1} \underline{x}}_{\text{linear term}} - \underbrace{\frac{1}{2} \underline{\mu}_c^T \underline{\Sigma}_c^{-1} \underline{\mu}_c}_{\text{constant}} - \frac{1}{2} \log(\det \underline{\Sigma}_c) - \frac{n}{2} \log(2\pi) + \log \pi_c$$

quadratic
 $A = -\frac{1}{2} \underline{\Sigma}_c^{-1}$

linear term
 $B = -\underline{\mu}_c^T \underline{\Sigma}_c^{-1}$

constant
 C

Base on pmt.

→ Decision Rule : $g_1(\underline{x}) = g_2(\underline{x})$

$$\underline{x}^T (A_1 - A_2) \underline{x} + (B_1 - B_2) \underline{x} + (C_1 - C_2) = 0$$

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}_{n \times 1}$$

ถ้า $\underline{\Sigma}_1 = \underline{\Sigma}_2 = \dots = \underline{\Sigma}_c = \underline{\Sigma}$

Class ทุก Class มี covariance matrix เท่ากัน
⇒ เทอมนี้จะถูกตัดออก ⇒ LDA

Example: conditional 2D Gaussians

กรณีอื่น $\Sigma_c = \sigma_c^2 \cdot I_n$ (ทุก features มี independent นนด)

$$\begin{aligned} \rightarrow (\sigma_1^2 - \sigma_2^2) \underline{X}^T \underline{X} - \left(\frac{\mu_1^T}{\sigma_1^2} - \frac{\mu_2^T}{\sigma_2^2} \right) \underline{X} - \frac{1}{2} \left(\frac{\mu_1^T \mu_1}{\sigma_1^2} - \frac{\mu_2^T \mu_2}{\sigma_2^2} \right) \\ - \frac{1}{2} \log(\sigma_1^2 / \sigma_2^2) - \frac{n}{2} \log(2\pi) + \log(\pi^n / \sigma_c^n) = 0. \end{aligned}$$

$$\begin{aligned} g_c(x | \mu_c, \Sigma_c) &\propto \prod_{j=1}^m p([x_j^i]_{i \in [n]} | y_j) \quad \rightarrow \text{หน้าที่เราคือเราทำ MLE} \\ &\quad \text{เพื่อหา } \hat{\theta} \text{ ที่เหมาะสม.} \\ &= \sum_{j=1}^m \log[p(x_j^1, x_j^2, \dots, x_j^n | y_j)] \\ &= \sum_{j=1}^m \left(\sum_{i=1}^n \log[p(x_j^i | y_j)] \right) \quad \leftarrow \text{Conditional Independent.} \\ &\quad \downarrow \\ &\text{จากนี้เราก็ไปหา } j \text{ PDF ของแต่ละ feature มา.} \end{aligned}$$

Example: conditional 2D Gaussians แนวข้อสอบ Midterm.

Part 1. 16th Feb

1. Model selection
2. Validation techniques
3. Linear regression
4. Outlier analysis

Part 2. 18th Feb

1. Evaluation for **binary** classification
2. Evaluation for **multiclass** classification
3. Generative classifiers: LDA/QDA/Naive Bayes.

You can bring

1. One handwritten-A4 cheat sheet for each part.
2. You will need to write your answer with pen. So, don't forget to also bring the liquid eraser.
3. A calculator.

AIC, BIC

ถ้าเห็นการทดลองนี้คิดว่าเช่น Hold, K-Fold,... ข้อดี-ข้อเสีย

→ Derive Linear Regression แปลงๆ แบบที่เรียนเรา: correlate $(\vec{w}, \vec{y})$

→ แยกออกมัยเป็น cross-validate แบบไหน

→ Concept Base, อ่าน P-value ได้มัย, Non Para vs Para?

ดู β เป็นไอ.

การ Normalize X

↓
สมมติว่าให้ H-matrix มา
บอกได้มัยว่า High-Low, outlier.

→ Confusion Matrix Micro, Macro ยังไง

→ Derive LDA/QDA/Naive $\leadsto$ discriminant f_x

→ Calculate เบาะๆ.

↓
Gaussian, Naive Bayes เป็นไงทำได้มัย.